

Programmazione parallela in Haskell : strategie e prestazioni



*Candidato : Andrea Senese
Relatore : Prof. Ugo de' Liguoro*

*Università degli Studi di Torino
Scuola di Scienze Matematiche, Fisiche e Naturali
Dipartimento di Informatica
Laurea Triennale in Informatica - Linguaggi e Sistemi*

- 1 *Cos'è Haskell?*
- 2 *Determinismo in Haskell*
- 3 *Monadi per effettuare azioni non Deterministiche*
- 4 *Parallel Haskell : Monade Eval e Strategie*
- 5 *Monade Par*
- 6 *Parallel Type Inference Algorithm*

- *Haskell* è un *linguaggio di programmazione avanzato e puramente funzionale* (basato sul sistema formale *lambda calcolo*) e prende nome dal matematico-logico statunitense Haskell Curry;
- Adatto per *l'insegnamento*, la *ricerca*, per sviluppare *applicazioni* e la *costruzione di grandi sistemi*;
- Completamente descritto attraverso la pubblicazione di una *sintassi* e una *semantica formale*;
- Haskell è un linguaggio per cui la valutazione risulta "lazy";
- No effetti collaterali (no side effect) \Rightarrow *deterministico* e per sua natura è possibile adottare tecniche di *parallelismo*.



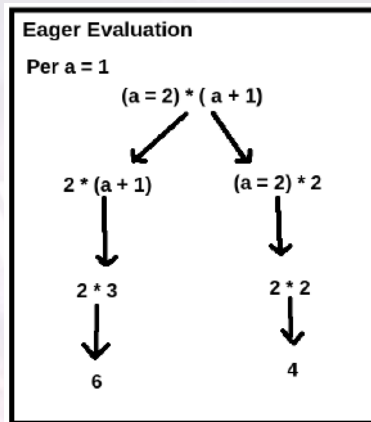



Figure 1: *Lazy Evaluation vs Eager Evaluation*

- Dato un termine M che si riduce in uno o più passi di calcolo in N_1 e N_2 , allora esiste un N tale che N_1 si riduce a N (in uno o più passi di calcolo) e N_2 si riduce a N (in uno o più passi di calcolo). Formalmente:

Theorem (Church-Ross Confluence)

Se $M \rightarrow N_1$ e $M \rightarrow N_2$ allora $\exists N$ tale che $N_1 \rightarrow N$ e $N_2 \rightarrow N$

Dimostrazione:

Supponiamo che N_1 e N_2 sono due forme normali di M , allora per il teorema di confluenza sappiamo che N_1 si riduce a N (in 0 passi) e lo stesso N_2 e quindi per transitività abbiamo che:

$$(N_1 = N \wedge N_2 = N) \Rightarrow N_1 = N_2$$

Monadi per introdurre il non Determinismo(side effect)



- Le **Monadi** in **Haskell** possono essere pensate come descrizioni computabili di calcoli;
- **Monade** \Rightarrow composizione di classi di computazioni in modo da poter trasportare dati extra. Questo permette la realizzazione di operazioni come I/O, State, handler, ...;
- Una monade è caratterizzata da:
 - ▶ T la tipologia del costrutto \Rightarrow equivale al **costruttore di tipo M** ;
 - ▶ μ è una funzione che permette la concatenazione o la composizione di monadi della stessa tipologia \Rightarrow equivale al **bind** ($>>=$);
 - ▶ η è una funzione che permette il passaggio da $(a \rightarrow T a) \Rightarrow$ equivale al **return**.

Monad

```
class Monad m where
    (>>=)  :: m a -> (a -> m b) -> m b
    (>>)   :: m a -> m b -> m b
    return :: a -> m a
    fail   :: String -> m a
```

Monadi per introdurre il non Determinismo(side effect)




Figure 2: *Monade*




Figure 3: *Parallelismo* \neq *Concorrenza*

- Il *Parallelismo* e la *Concorrenza* sono concetti distinti:
 - ▶ *Parallelism* significa che diversi thread lavorano sullo stesso task per ridurre un calcolo in forma normale ottimizzando i tempi di risposta \Rightarrow *Determinismo*;
 - ▶ La *Concorrenza* consiste nell'eseguire task differenti da parte di più thread alternandosi la CPU \Rightarrow *Non Determinismo*.
- *Haskell* offre i seguenti strumenti al programmatore per parallelizzare i propri programmi:
 - ▶ *Monade Eval* e *Strategie*;
 - ▶ *Monade Par*.

- **Monade Eval** è il primo approccio per esprimere il **Parallelismo** in **Haskell** dal modulo **Control.Parallel.Strategies**. Si hanno 3 operatori base nella **Monade Eval**:
 - ▶ **runEval** → Computa l'operazione nell'**Eval Monad** e ritorna il risultato;
 - ▶ **rpar** → L'argomento potrebbe essere valutato in parallelo;
 - ▶ **rseq** → Forza la valutazione sequenziale e si mette in attesa del risultato.
- Per esempio :




Figure 4: **rpar/rpar** e **rpar/rseq**

- La soluzione è:




Figure 5: *rpar/rpar/rseq/rseq*

- La *Monade Eval* è integrata in un programma di diagnostica chiamato *Threadscope*.

- *Esiste una relazione stretta tra **Monade Eval** e **Strategie**. Le **Strategie** possono essere pensate come un'astrazione di livello superiore per alleviare molti dei problemi associati alla regolazione della granularità e alla forzatura della valutazione manuale; Le **Strategie** hanno le seguenti caratteristiche:*
 - ▶ *Le **Strategie** esprimono parallelismo deterministico: il risultato del programma non è influenzato dalla valutazione in parallelo. I task parallel valutati con le **Strategie** non hanno side effect;*
 - ▶ *Le **Strategie** consentono di separare il parallelismo dalla logica del programma, permettendo parallelismo modulare. L'idea di base è quella di costruire una struttura dati lazy che rappresenti il calcolo, e quindi scrivere una strategia che descriva come attraversare la struttura dei dati e valutarne i componenti in sequenza o in parallelo;*
 - ▶ *Le **Strategie** sono composizionali: grandi strategie possono essere costruite componendo strategie più piccole.*

- **Threadscope** venne creato per aiutare i programmatori nel visualizzare l'esecuzione parallela dei programmi **Haskell** compilati con **GHC**. L'idea è che quando viene eseguito un programma parallelo in **Haskell**, il sistema di runtime di **Haskell** scrive data e tempistiche di eventi significativi in un log file. Il tool **Threadscope** allora leggerà il log file, e mostrerà graficamente all'utente cosa stava facendo la **CPU** in quell'intervallo di tempo. Il diagramma mostra al programmatore in quali istanti il programma viene eseguito in parallelo, e dove no.




Figure 6: il tool Threadscope


- Gli strumenti menzionati finora portano a tassi di fallimento elevati perché *rpar* richiede al programmatore di comprendere le proprietà operative del programma che risiedono, nella maggior parte dei casi, nell'implementazione;
- Un'altra pratica utilizzata per correggere le loro debolezze è la *Monade Eval*, che purtroppo è ancora limitata (e non va molto lontana);
- La *Monade Par* offre le seguenti operazioni di base:
 - ▶ *runPar* → computa l'operazione nella *Monade Par* e *ritorna* il risultato;
 - ▶ *fork* → crea un nuovo *Thread*;
 - ▶ *new* → create un nuovo *IVar*;
 - ▶ *get* → get the result written in the *IVar*;
 - ▶ *put* → writes the result in the *IVar*.

IVar

L'*IVar* è una variabile immutabile che è possibile scrivere una sola volta e poi verrà bloccata (per garantire determinismo).

La *Monade Par* non è attualmente integrata in *Threadscope*.

- **Criterion** è un libreria che fornisce un modo semplice per misurare le prestazioni del software tramite definizione di benchmark;
- il flag `"--option nomefile.html"` indica al nostro programma di scrivere un report nel file HTML;
- Si ha un elenco di valori di benchmark dove ognuno corrisponde a una funzione da esaminare.



```
import Criterion.Main

-- The function we're benchmarking.
fib m | m < 0      = error "negative!"
      | otherwise = go m
  where
    go 0 = 0
    go 1 = 1
    go n = go (n-1) + go (n-2)

-- Our benchmark harness.
main = defaultMain [
  bgroup "fib" [ bench "1"  $ whnf fib 1
                , bench "5"  $ whnf fib 5
                , bench "9"  $ whnf fib 9
                , bench "11" $ whnf fib 11
                ]
]
```

Figure 7: Test Criterion + Report

- *Un esempio che si adatta naturalmente al dataflow model è l'analisi del programma, in cui le informazioni vengono in genere propagate dai punti di definizione ai punti di utilizzo nel programma;*
- *L'inferenza di tipo dà origine a un dataflow graph; ogni binding è un nodo nel grafo con input corrispondente alle variabili libere dell'associazione e un singolo output rappresenta il tipo derivato per quel binding. Ad esempio, il seguente insieme di bindings può essere rappresentato dal dataflow graph sotto riportato:*




Figure 8: *Dataflow graph of bindings*

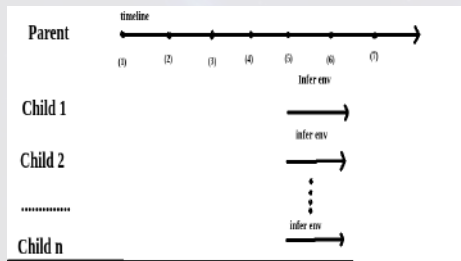
Definiamo la funzione `parinfer` come segue:

`parInfer`

```
--(1)
parInfer :: [(Var, Expr)] -> [(Var, Type)]
parInfer bindings = runPar $ do
    let binders = map fst bindings --(2)
    ivars <- replicateM (length binders) new --(3)
    let env = Map.fromList (zip binders ivars) --(4)
    mapM_ (fork . infer env) bindings --(5)
    types <- mapM_ get ivars --(6)
    return (zip binders types) --(7)
```


Parallel Type Inference Algorithm

Un'esecuzione concreta :



- (1) `call parInfer -> parInfer [(var1,exp1),(var2,exp1),...,(var_n,exp_n)]`
- (2) `let binders = map fst [(var1,exp1),(var2,exp1),...,(var_n,exp_n)] = [var1,var2,...,var_n] (forall elem in list apply fst(elem))`
- (3) `ivars = replicateM (length [(var1,exp1),(var2,exp1),...,(var_n,exp_n)]) new = replicateM n new = [Ivar1,Ivar2,..., Ivar_n]`
(create a list of length n with n Ivar)
- (4) `env = Map.fromList (zip [var1,var2,...,var_n] [Ivar1,Ivar2,...,Ivar_n]) = Map.fromList [(var1,Ivar1),(var2,Ivar2),...,(var_n,Ivar_n)] =`

| Key | Value |
|-----|-------|
| 1 | var1 |
| ... | ... |
| n | var_n |

- (5) Infer calls put for each binding in the list for write the type in the Ivar mapped by that variable in env.
- (6) `type = mapM_get [Ivar1,...,Ivar_n] = [type1,type2,...,type_n]`
(wait the result computed by the childs).
- (7) `return (zip [var1,var2,...,var_n] [type1,type2,...,type_n]) = [(var1,type1),...,(var_n,type_n)] (return the result)`

- *Questa implementazione estrae il massimo parallelismo nella struttura di dipendenza di un determinato insieme di bindings, con pochissimo sforzo da parte del programmatore;*
- *Lo stesso trucco può essere fatto usando la valutazione lazy, e in effetti potremmo ottenere la stessa struttura parallela usando la valutazione lazy insieme alle Strategie, ma il vantaggio della versione Par monad è che la struttura è programmata esplicitamente e il comportamento a runtime non è legato a una particolare strategia di valutazione (o compilatore).*

Parallel Type Inference Algorithm : Threadscope



- In *Threadscope*:



Figure 9: *ParInfer* visto in *Threadscope* su una CPU quad-core con 8-threads.




Figure 10: *ParInfer* visto in *Threadscope* su una CPU quad-core limitata a 2 core



criterion performance measurements

overview

want to understand this report?



parInferBinds/file_benchmark



| | lower bound | estimate | upper bound |
|--------------------------------|-------------|----------|-------------|
| OLS regression | 884 ms | 934 ms | 959 ms |
| R ² goodness-of-fit | 0.999 | 1.000 | 1.000 |
| Mean execution time | 938 ms | 945 ms | 950 ms |
| Standard deviation | 1.73 ms | 7.39 ms | 9.84 ms |

Outlying measurements have moderate (18.8%) effect on estimated standard deviation.

GRAZIE A TUTTI PER L'ATTENZIONE

